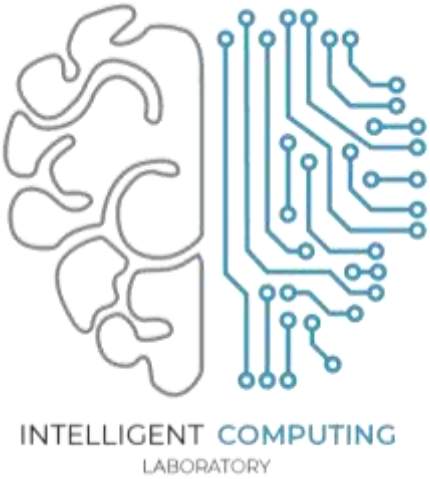
LAPORAN PRAKTIKUM

PEMBELAJARAN MESIN



NAMA : HADIJAH TOHEPALY

NIM : 202431078

KELAS : C

DOSEN :

NO.PC : 12

ASISTEN :

1. MUHAMMAD RAKA ILHAM
2. MUHAMMAD JABBAR
3. MUHAMMAD FACHRYDZI IRFANSYAH
4. SHARIRA MAHARANI

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

1. EDA

- Judul Dataset: California Housing Prices
- Jumlah data: 20.640 baris × 10 kolom
- Link Kaggle: [California Housing Prices – Kaggle]
- Deskripsi: Dataset berisi informasi perumahan di California berdasarkan sensus tahun 1990, seperti lokasi, jumlah kamar, pendapatan, dan harga rumah. Dataset ini dapat digunakan untuk menganalisis karakteristik perumahan dan mempelajari prediksi harga rumah.

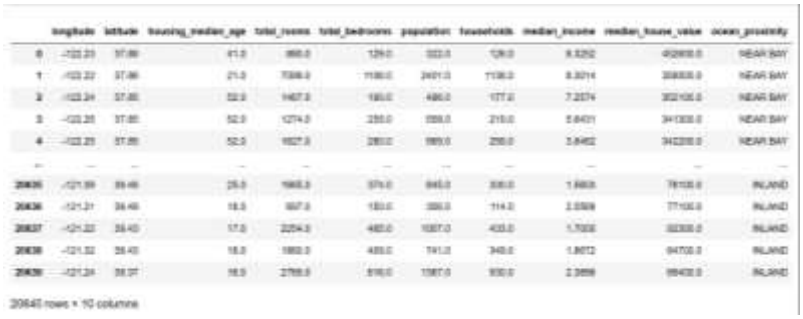
```
In [1]: # Import Library
        # Hadijah Tohepaly_202431078

        import pandas as pd
        import matplotlib.pyplot as plt
```

```
In [2]: # Membaca dan menampilkan dataset
        # Hadijah Tohepaly_202431078

        df = pd.read_csv("housing.csv")

        df
```



Library ini gunanya mengimpor library pandas untuk mengolah data dan matplotlib buat visualisasi berupa grafik. Dan kode juga untuk menampilkan informasi dataset, seperti jumlah data, tipe data, dan jumlah data yang terisi pada setiap kolom. Output menunjukkan dataset California Housing yang terdiri dari 20.640 baris dan 10 kolom, berisi informasi mengenai kondisi perumahan di California.

```
In [3]: # Melihat deskripsi statistik
        # Hadijah Tohepaly_202431078

        df.describe()
```



df.describe() digunakan untuk menampilkan ringkasan statistik dari seluruh kolom numerik pada dataset, seperti jumlah data, rata-rata, standar deviasi, nilai minimum, kuartil, dan maksimum. Output menunjukkan ringkasan statistik dataset California Housing, seperti jumlah data sebanyak 20.640 baris, rata-rata usia rumah 28,64 tahun, rata-rata jumlah kamar 2.635,76, serta rata-rata harga rumah sebesar 206.855,82. Selain itu, output menampilkan nilai minimum, maksimum, median, dan persebaran data pada setiap kolom numerik.

```
In [4]: # Menghitung missing value
        # Hadijah Tohepaly_202431078

        df.isna().sum()
```

```
Out[4]: longitude             0
        latitude              0
        housing_median_age    0
        total_rooms           0
        total_bedrooms      207
        population            0
        households            0
        median_income         0
        median_house_value    0
        ocean_proximity       0
        dtype: int64
```

```
In [5]: # Melihat nilai unik kolom kategorik
        # Hadijah Tohepaly_202431078

        df["ocean_proximity"].unique()
```

```
Out[5]: array(['NEAR BAY', '<1H OCEAN', 'INLAND', 'NEAR OCEAN',
               dtype=object)
```

df.isna().sum() digunakan untuk menghitung jumlah data kosong pada setiap kolom dataset. Dan Hasil menunjukkan terdapat 207 data kosong pada kolom total_bedrooms, sedangkan kolom lainnya tidak memiliki data kosong. Kode df["ocean_proximity"].unique() digunakan untuk menampilkan seluruh nilai unik atau kategori yang terdapat pada kolom ocean_proximity tanpa menampilkan nilai yang berulang. Dan output menunjukkan terdapat 5 kategori lokasi perumahan, yaitu NEAR BAY, <1H OCEAN, INLAND, NEAR OCEAN, dan ISLAND, yang menggambarkan kedekatan lokasi perumahan dengan laut.

```
In [6]: # Menangani missing value
        # Hadijah Tohepaly_202431078

        # Mengisi missing value kolom numerik dengan mean
        for kolom in df.select_dtypes(include="number").columns:
            df[kolom] = df[kolom].fillna(df[kolom].mean())

        # Mengisi missing value kolom kategorik dengan modus
        for kolom in df.select_dtypes(include="object").columns:
            df[kolom] = df[kolom].fillna(df[kolom].mode()[0])

In [7]: df.isna().sum()
```

```
Out[7]: longitude           0
        latitude            0
        housing_median_age  0
        total_rooms         0
        total_bedrooms      0
        population          0
        households          0
        median_income       0
        median_house_value  0
        ocean_proximity     0
        dtype: int64
```

Kode tersebut digunakan untuk menangani missing value dengan mengisi data kosong pada kolom numerik menggunakan nilai rata-rata dan kolom kategorik menggunakan nilai yang paling sering muncul, kemudian menyimpan hasilnya kembali ke dataset. Output menunjukkan seluruh kolom memiliki missing value sebanyak 0, yang berarti semua data kosong pada dataset telah berhasil ditangani.

```
In [8]: # Menghitung data duplikat
        # Hadijah Tohepaly_202431078

        df.duplicated().sum()
```

```
Out[8]: 0
```

```
In [9]: # Menghapus data duplikat
        # Hadijah Tohepaly_202431078
        df = df.drop_duplicates()

        df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 20640 entries, 0 to 20639
Data columns (total 10 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   longitude           20640 non-null  float64
 1   latitude            20640 non-null  float64
 2   housing_median_age  20640 non-null  float64
 3   total_rooms         20640 non-null  float64
 4   total_bedrooms      20640 non-null  float64
 5   population          20640 non-null  float64
 6   households          20640 non-null  float64
 7   median_income       20640 non-null  float64
 8   median_house_value  20640 non-null  float64
 9   ocean_proximity     20640 non-null  object
dtypes: float64(9), object(1)
memory usage: 1.7+ MB
```

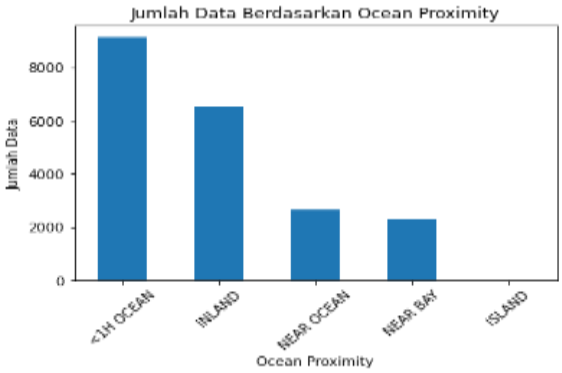
Kode df.duplicated().sum() digunakan untuk menghitung jumlah baris data yang duplikat, sedangkan df.drop_duplicates() digunakan untuk menghapus data duplikat dan menyimpan hasilnya kembali ke dataset. Output menunjukkan jumlah data duplikat adalah 0, sehingga tidak ditemukan baris data yang sama. Setelah dilakukan penghapusan duplikat, dataset tetap memiliki 20.640 baris dan 10 kolom, seluruh data terisi, serta tidak terdapat missing value maupun data duplikat.

```
In [10]: df.duplicated().sum()
Out[10]: 0

In [11]: # Visualisasi data menggunakan diagram batang
         # Hadijah Tohepaly_202431078

         df["ocean_proximity"].value_counts().plot(kind="bar")

         plt.title("Jumlah Data Berdasarkan Ocean Proximity")
         plt.xlabel("Ocean Proximity")
         plt.ylabel("Jumlah Data")
         plt.xticks(rotation=45)
         plt.show()
```



Membuat diagram batang jumlah data berdasarkan kategori ocean_proximity beserta judul dan label sumbu. Output menunjukkan bahwa kategori <1H OCEAN memiliki jumlah data terbanyak, sedangkan ISLAND memiliki jumlah data paling sedikit. Grafik ini menggambarkan distribusi jumlah perumahan berdasarkan kategori kedekatan dengan laut.

2. Scraping

```
In [1]: # Import library
        # Hadijah Tohepaly_202431078

        !pip install requests beautifulsoup4 pandas

        Requirement already satisfied: requests in c:\users\h
        Requirement already satisfied: beautifulsoup4 in c:\u
        Requirement already satisfied: pandas in c:\users\had
```

```
In [2]: # Import Library
        # Hadijah Tohepaly_202431078

        import requests
        import csv
        from bs4 import BeautifulSoup
        import pandas as pd
```

Kode tersebut digunakan untuk menginstal dan mengimpor library Python yang berfungsi untuk mengambil data dari website. Lalu yang bagian Library untuk membaca file CSV, serta mengolah data menggunakan Pandas dan BeautifulSoup.

```
# Mengambil halaman website
# Hadijah Tohepaly_202431078

url = "https://magicscraper.app/demo/bulk"

headers = {
    "User-Agent": "Mozilla/5.0"
}

response = requests.get(url, headers=headers)

print("Status:", response.status_code)

Status: 200
```

```
# Mengubah HTML menjadi objek BeautifulSoup
# Hadijah Tohepaly_202431078

soup = BeautifulSoup(response.text, "html.parser")

print(soup.prettify()[:3000])

<!DOCTYPE html>
<html lang="en">
 <head>
```

```
# Mencari tabel produk
# Hadijah Tohepaly_202431078

table = soup.find("table")

print("Tabel ditemukan:", table is not None)

rows = table.find_all("tr")

print("Jumlah baris:", len(rows))

Tabel ditemukan: True
Jumlah baris: 51
```

Kode tersebut digunakan untuk mengakses website menggunakan Requests, memeriksa status koneksi, mengubah halaman HTML menjadi objek BeautifulSoup agar struktur website mudah dibaca, kemudian mencari tabel pada halaman dan menghitung jumlah baris data yang terdapat di dalamnya.

```
# Scraping 200 data produk
# Hadijah Tohepaly_202431078

result = []

for halaman in range(1, 5):

    if halaman == 1:
        url = "https://magicscraper.app/demo/bulk"
    else:
        url = f"https://magicscraper.app/demo/bulk{halaman}"

    response = requests.get(url, headers=headers)

    soup = BeautifulSoup(response.text, "html.parser")

    table = soup.find("table")

    rows = table.find_all("tr")

    print(f"Halaman {halaman}: {len(rows)-1} baris")
```

```
    for row in rows[1:]:

        cols = row.find_all("td")

        if len(cols) >= 11:

            result.append({
                "sku": cols[0].get_text(strip=True),
                "nama_produk": cols[1].get_text(strip=True),
                "merk": cols[2].get_text(strip=True),
                "kategori": cols[3].get_text(strip=True),
                "pack": cols[4].get_text(strip=True),
                "harga": cols[5].get_text(strip=True),
                "harga_sebelumnya": cols[6].get_text(strip=True),
                "stock": cols[7].get_text(strip=True),
                "lead_time": cols[8].get_text(strip=True),
                "rating": cols[9].get_text(strip=True),
                "reviews": cols[10].get_text(strip=True)
            })

print("Jumlah data:", len(result))
```

```
Halaman 1: 50 baris
Halaman 2: 50 baris
Halaman 3: 50 baris
Halaman 4: 50 baris
Jumlah data: 200
```

Kode tersebut digunakan untuk melakukan web scraping pada 4 halaman website secara berulang, mengambil data produk dari setiap tabel, menyimpan informasi seperti SKU, nama produk, kategori, harga, stok, dan rating ke dalam list result, serta menghitung total 200 data produk yang berhasil dikumpulkan.

```
# Menampilkan hasil scraping
# Hadijah Tohepaly_202431078

for data in result[:10]:
    print(data)
```

```
{'sku': 'NWT-10000', 'nama_produk
'1', 'harga': '$186.94', 'harga_s
s': '289'}
```

```
# Mencari link produk
# Hadijah Tohepaly_202431078

for tag in soup.find_all("a", href=True):
    print(tag.get_text(strip=True), tag["href"])
```

```
Download Tokopedia App /mobile-apps/
Tentang Tokopedia /about/
Mulai Berjualan https://seller.tokopedia.com/edu
Promo /promo/
```

```
# Menyimpan hasil scraping ke CSV
# Hadijah Tohepaly_202431078

with open("hasil_scraping.csv", "w",
          newline="", encoding="utf-8") as file:

    fieldnames = [
        "sku", "nama_produk", "maker", "kategori",
        "pack", "harga", "harga_sebelumnya",
        "stock", "lead_time", "rating", "reviews"
    ]

    writer = csv.DictWriter(
        file, fieldnames=fieldnames
    )

    writer.writeheader()
    writer.writerows(result)

print("CSV berhasil disimpan")
```

```
CSV berhasil disimpan
```

Kode tersebut digunakan untuk menampilkan 10 data produk pertama hasil scraping, mengambil dan menampilkan seluruh link pada website, serta menyimpan 200 data produk yang telah dikumpulkan ke dalam file CSV bernama hasil_scraping.csv agar dapat digunakan untuk pengolahan data lebih lanjut.

```
# Membaca hasil scraping
# Hadijah Tohepaly_202431078

df = pd.read_csv("hasil_scraping.csv")

df.head()
```

	sku	nama_produk	maker	kategori	pack	harga	harga_sebelumnya	stock	lead_time	rating	reviews
0	NWT-10000	Cast Iron Mug Set, Oat — Small	Fieldhouse	Tabletop	1	$186.94	NaN	In stock	2 weeks	★★★★★4.6	209
1	NWT-10001	Wool Skillet, Large — Medium	Aoyama Works	Kitchen	2	$137.45	NaN	In stock	2–3 days	★★★★☆4.5	261
2	NWT-10002	Walnut Side Table, Large — Large	Tessa Ruiz Studio	Furniture	2	$88.88	NaN	Low stock	ships today	★★★☆☆3.2	128
3	NWT-10003	Wool Bowl, Clay — Extra large	Aoyama Works	Tabletop	6	$95.54	NaN	Low stock	4–6 weeks	★★★★★4.8	165
4	NWT-10004	Slate Vase, Ink — Natural	Brock Forge	Decor	2	$386.92	NaN	Low stock	1 week	★★★★☆4.0	280

Kode tersebut digunakan untuk membaca file hasil_scraping.csv menggunakan Pandas dan menampilkan 5 baris data pertama melalui df.head() sebagai preview hasil scraping dalam bentuk tabel yang berisi informasi produk.

```
# Mengubah kolom numerik
# Hadijah Tohepaly_202431078

df["harga"] = pd.to_numeric(
    df["harga"].str.replace(r"[^0-9.]", "", regex=True),
    errors="coerce"
)

df["rating"] = pd.to_numeric(
    df["rating"].str.extract(r"(\d+\.\d+)")[0],
    errors="coerce"
)

df["reviews"] = pd.to_numeric(
    df["reviews"], errors="coerce"
)

df["pack"] = pd.to_numeric(
    df["pack"], errors="coerce"
)

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 11 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   sku               200 non-null    object
 1   nama_produk       200 non-null    object
 2   maker             200 non-null    object
 3   kategori          200 non-null    object
 4   pack              200 non-null    int64
 5   harga             200 non-null    float64
 6   harga_sebelumnya  75 non-null     object
 7   stock             200 non-null    object
 8   lead_time         200 non-null    object
 9   rating            200 non-null    float64
 10  reviews           200 non-null    int64
dtypes: float64(2), int64(2), object(7)
memory usage: 17.3+ KB
```

Kode tersebut digunakan untuk membersihkan dan mengubah kolom harga, rating, reviews, dan pack menjadi tipe numerik, sedangkan output df.info() menunjukkan bahwa dataset memiliki 200 baris dan 11 kolom dengan tipe data yang sesuai, serta terdapat 75 data terisi pada kolom harga_sebelumnya.

```
# Menyimpan dataset akhir
# Hadijah Tohepaly_202431078

df.to_csv("hasil_scraping.csv", index=False)

print("Jumlah data:", len(df))

df.head()
```

```
Jumlah data: 200
```

	sku	nama_produk	maker	kategori	pack	harga	harga_sebelumnya	stock	lead_time	rating	reviews
0	NWT-10000	Cast Iron Mug Set, Oat — Small	Fieldhouse	Tabletop	1	186.94	NaN	In stock	2 weeks	4.6	209
1	NWT-10001	Wool Skillet, Large — Medium	Aoyama Works	Kitchen	2	137.45	NaN	In stock	2–3 days	4.5	261
2	NWT-10002	Walnut Side Table, Large — Large	Tessa Ruiz Studio	Furniture	2	88.88	NaN	Low stock	ships today	3.2	128
3	NWT-10003	Wool Bowl, Clay — Extra large	Aoyama Works	Tabletop	6	95.54	NaN	Low stock	4–6 weeks	4.8	165
4	NWT-10004	Slate Vase, Ink — Natural	Brock Forge	Decor	2	386.92	NaN	Low stock	1 week	4.0	280

Kode tersebut digunakan untuk menyimpan kembali dataset yang telah dibersihkan ke file CSV tanpa menyertakan indeks, menampilkan jumlah data sebanyak 200 baris, serta memperlihatkan 5 baris pertama dataset sebagai hasil akhir pengolahan data scraping.

```
# Membersihkan kolom harga sebelumnya
# Hadijah Tohepaly_202431078

df["harga_sebelumnya"] = pd.to_numeric(
    df["harga_sebelumnya"].astype(str).str.replace(
        r"[^0-9.]", "", regex=True
    ),
    errors="coerce"
)

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 11 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   sku               200 non-null    object
 1   nama_produk       200 non-null    object
 2   maker             200 non-null    object
 3   kategori          200 non-null    object
 4   pack              200 non-null    int64
 5   harga             200 non-null    float64
 6   harga_sebelumnya  75 non-null     float64
 7   stock             200 non-null    object
 8   lead_time         200 non-null    object
 9   rating            200 non-null    float64
 10  reviews           200 non-null    int64
dtypes: float64(3), int64(2), object(6)
memory usage: 17.3+ KB
```

```
# Menyimpan dataset final
# Hadijah Tohepaly_202431078

df.to_csv("hasil_scraping.csv", index=False)

print("Jumlah data:", len(df))
print("Dataset berhasil disimpan")
```

```
Jumlah data: 200
Dataset berhasil disimpan
```

Kode tersebut digunakan untuk membersihkan kolom harga_sebelumnya dengan mengubahnya menjadi tipe numerik, memeriksa struktur dan tipe data menggunakan df.info(), serta menyimpan kembali dataset ke file CSV dengan total 200 data yang berhasil diproses.

3. Regresi Linear

```
# Hadijah Tohepaly - 202431078
# 1. Import Library
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# 2. Membaca Dataset
df = pd.read_csv("hasil_scraping.csv")

# Menampilkan data
df.head()
```

	sku	nama_produk	maker	kategori	pack	harga	harga_sebelumnya	stock	lead_time	rating	reviews
0	NWT-10000	Cast Iron Mug Set, Oat — Small	Fieldhouse	Tabletop	1	186.94	NaN	In stock	2 weeks	4.8	209
1	NWT-10001	Wool Skillet, Large — Medium	Aoyama Works	Kitchen	2	157.45	NaN	In stock	2–3 days	4.5	261
2	NWT-10002	Walnut Side Table, Large — Large	Tessa Ruiz Studio	Furniture	2	66.68	NaN	Low stock	ships today	3.2	128
3	NWT-10003	Wool Bowl, Clay — Extra large	Aoyama Works	Tabletop	6	66.54	NaN	Low stock	4–6 weeks	4.8	165
4	NWT-10004	Slate Vase, Ink — Natural	Brock Forge	Decor	2	366.92	NaN	Low stock	1 week	4.0	280

Kode tersebut mengimpor library NumPy, Pandas, Matplotlib, dan Scikit-learn untuk pengolahan data, visualisasi, serta regresi linear, kemudian membaca dataset hasil_scraping.csv menggunakan Pandas dan menampilkan lima data produk pertama yang terdiri dari 11 atribut, seperti SKU, nama produk, kategori, harga, rating, dan jumlah ulasan.

```
# Hadijah Tohepaly_202431078
# 3. Menghapus Data Kosong
df = df.dropna(subset=["harga_sebelumnya", "harga"])

# 4. Menentukan Fitur dan Target
X = df[["harga_sebelumnya"]]
y = df["harga"]

# Menampilkan jumlah data
print("Jumlah data:", len(df))
```

```
Jumlah data: 75
```

```
# Hadijah Tohepaly_202431078
# 5. Membagi Data
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0
)

print("Data latih:", len(X_train))
print("Data uji:", len(X_test))
```

```
Data latih: 60
Data uji: 15
```

```
# Hadijah Tohepaly_202431078
# 6. Membuat Model
model = LinearRegression()

# 7. Melatih Model
model.fit(X_train, y_train)
```

```
LinearRegression()
```

Kode tersebut menghapus data yang memiliki nilai kosong pada kolom harga sebelumnya dan harga sehingga tersisa 75 data, menentukan harga_sebelumnya sebagai fitur (X) dan harga sebagai target (y), membagi data menjadi 60 data latih dan 15 data uji, kemudian membuat serta melatih model regresi linear menggunakan LinearRegression() untuk mempelajari hubungan antara harga sebelumnya dan harga produk.

```
# Hadijah Tohepaly_202431078
# 8. Prediksi Data Uji
y_pred = model.predict(X_test)

# Menampilkan hasil prediksi
hasil = pd.DataFrame({
    "Harga Sebelumnya": X_test["harga_sebelumnya"],
    "Harga Aktual": y_test,
    "Harga Prediksi": y_pred
})

hasil.head()
```

	Harga Sebelumnya	Harga Aktual	Harga Prediksi
137	1898.86	1769.25	1470.104155
150	481.30	387.29	387.662312
54	358.47	291.10	293.869928
199	230.81	187.35	196.389380
70	233.04	202.65	198.092197

Kode tersebut menggunakan model.predict(X_test) untuk memprediksi harga produk berdasarkan harga sebelumnya pada 15 data uji, kemudian menampilkan tabel perbandingan harga sebelumnya, harga aktual, dan harga prediksi, di mana hasil prediksi menunjukkan perkiraan harga produk yang dihasilkan oleh model regresi linear.

```
# Hadijah Tohepaly_202431078
# 9. Evaluasi Model

print("Koefisien:", model.coef_[0])
print("Intercept:", model.intercept_)

mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("MSE:", mse)
print("R2 Score:", r2)
```

```
Koefisien: 0.7635950811868508
Intercept: 20.143999894866658
MSE: 7052.466582888891
R2 Score: 0.9591490487221133
```

```
# Hadijah Tohepaly_202431078
# 10. Persamaan Regresi

a = model.intercept_
b = model.coef_[0]

print(f"Persamaan Regresi: Y = {a:.2f} + {b:.4f}X")
```

```
Persamaan Regresi: Y = 20.14 + 0.7636X
```

Kode tersebut mengevaluasi model regresi linear dengan menghitung koefisien sebesar 0,7636, intercept sebesar 20,144, nilai MSE sebesar 7.052,47, dan R^2 sebesar 0,9591 atau 95,91%, kemudian menghasilkan persamaan regresi Y = 20,14 + 0,7636X, yang menunjukkan bahwa model memiliki kemampuan prediksi cukup baik dalam memperkirakan harga produk berdasarkan harga sebelumnya.

```
# Hadijah Tohepaly_202431078
# 11. Visualisasi Regresi Linear

plt.figure(figsize=(10, 6))

# Scatter Plot Data Aktual
plt.scatter(X_test["harga_sebelumnya"], y_test,
            color="blue", label="Data Aktual")

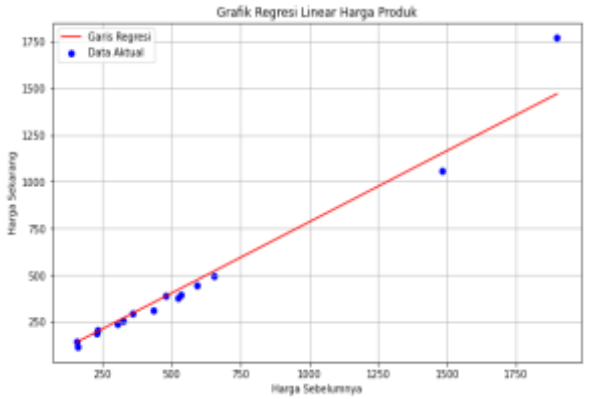
# Garis Regresi
x_garis = np.linspace(X_test["harga_sebelumnya"].min(),
                      X_test["harga_sebelumnya"].max(), 100)

y_garis = model.predict(pd.DataFrame({
    "harga_sebelumnya": x_garis
}))

plt.plot(x_garis, y_garis,
         color="red", label="Garis Regresi")

plt.title("Grafik Regresi Linear Harga Produk")
plt.xlabel("Harga Sebelumnya")
plt.ylabel("Harga Sekarang")
plt.legend()
plt.grid(True)

plt.show()
```



Kode tersebut memvisualisasikan hasil regresi linear menggunakan grafik scatter berwarna biru untuk menunjukkan data harga aktual dan garis merah untuk menunjukkan garis regresi, sehingga dapat terlihat hubungan antara harga sebelumnya dan harga sekarang serta seberapa dekat data aktual dengan garis prediksi model.

4. Decision Tree

```
# Hadijah Tohepaly-202431078
# 1. Import Library
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score, classification_report
```

Kode ini digunakan untuk mengimpor library Pandas, NumPy, Matplotlib, dan Scikit-learn yang berfungsi untuk mengolah data, mengubah data kategorikal menjadi numerik, membagi data latih dan uji, membuat model Decision Tree, serta mengevaluasi dan menampilkan hasil model.

```
# Hadijah Tohepaly-202431078
# 2. Membaca Dataset
df = pd.read_csv("hasil_scraping.csv")

df.head()
```

	sku	nama_produk	maker	kategori	pack	harga	harga_sebelumnya	stock	lead_time	rating	reviews
0	NWT-10000	Cast Iron Mug Set, Oat — Small	Fieldhouse	Tabletop	1	186.94	NaN	In stock	2 weeks	4.8	209
1	NWT-10001	Wool Skillet, Large — Medium	Aoyama Works	Kitchen	2	137.45	NaN	In stock	2–3 days	4.5	261
2	NWT-10002	Walnut Side Table, Large — Large	Tessa Ruiz Studio	Furniture	2	88.68	NaN	Low stock	ships today	3.2	128
3	NWT-10003	Wool Bowl, Clay — Extra large	Aoyama Works	Tabletop	6	95.54	NaN	Low stock	4–6 weeks	4.8	166
4	NWT-10004	Slate Vase, Ink — Natural	Brock Forge	Decor	2	386.92	NaN	Low stock	1 week	4.0	280

Kode pd.read_csv("hasil_scraping.csv") digunakan untuk membaca dataset hasil scraping dari file CSV ke dalam DataFrame df, sedangkan df.head() menampilkan lima baris pertama dataset yang berisi informasi produk seperti nama produk, harga, stok, rating, dan jumlah ulasan.

```
# Hadijah Tohepaly-202431078
# 3. Melihat Informasi Data
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   sku              200 non-null    object
 1   nama_produk      200 non-null    object
 2   maker            200 non-null    object
 3   kategori         200 non-null    object
 4   pack             200 non-null    int64
 5   harga            200 non-null    float64
 6   harga_sebelumnya 75 non-null     float64
 7   stock            200 non-null    object
 8   lead_time        200 non-null    object
 9   rating           200 non-null    float64
 10  reviews          200 non-null    int64
dtypes: float64(3), int64(2), object(6)
memory usage: 17.3+ KB
```

```
# Hadijah Tohepaly-202431078
# 4. Melihat Deskripsi Statistik
df.describe()
```

	pack	harga	harga_sebelumnya	rating	reviews
count	200.000000	200.000000	75.000000	200.000000	200.000000
mean	3.666000	463.068700	571.228000	3.998500	203.990000
std	3.693454	517.774022	619.106996	0.534677	114.021641
min	1.000000	14.810000	35.060000	3.100000	1.000000
25%	1.000000	166.670000	257.755000	3.800000	110.750000
50%	2.000000	336.255000	436.700000	3.900000	215.000000
75%	6.000000	453.687500	604.475000	4.400000	290.000000
max	12.000000	2979.070000	3784.960000	5.000000	419.000000

Kode df.info() digunakan untuk menampilkan informasi struktur dataset yang terdiri dari 200 baris dan 11 kolom beserta tipe datanya, sedangkan df.describe() digunakan untuk menampilkan statistik deskriptif seperti jumlah data, rata-rata, standar deviasi, nilai minimum, maksimum, dan kuartil pada kolom numerik, dengan harga_sebelumnya hanya memiliki 75 data terisi.

```
# Hadijah Tohepaly-202431078
# 5. Mengecek Data Kosong
df.isna().sum()
```

```
sku                0
nama_produk        0
maker              0
kategori           0
pack               0
harga              0
harga_sebelumnya   125
stock              0
lead_time          0
rating             0
reviews            0
dtype: int64
```

```
# Hadijah Tohepaly-202431078
# 6. Melihat Nilai Unik Kolom Target
print(df["kategori"].unique())
```

```
['Tabletop' 'Kitchen' 'Furniture' 'Decor' 'Lighting' 'Textiles']
```

Kode df.isna().sum() digunakan untuk menghitung jumlah data kosong pada setiap kolom, yang menunjukkan bahwa kolom harga_sebelumnya memiliki 125 data kosong, sedangkan df["kategori"].unique() digunakan untuk menampilkan enam kategori produk unik, yaitu Tabletop, Kitchen, Furniture, Decor, Lighting, dan Textiles.

```
# Hadijah Tohepaly-202431078
# 7. Memisahkan Fitur X dan Target y
X = df[["harga", "harga_sebelumnya", "stock",
        "lead_time", "rating", "reviews"]]

y = df["kategori"]
```

Kode X = df[...] digunakan untuk memilih enam kolom fitur berupa harga, harga sebelumnya, stok, lead time, rating, dan jumlah ulasan sebagai variabel input, sedangkan y = df["kategori"] digunakan untuk menentukan kolom kategori produk sebagai variabel target yang akan diprediksi oleh model Decision Tree.

```python
# Hadijah Tohepaly-202431078
# 8. Mengubah X dan y menjadi Array Angka

# Menyalin data fitur
X = X.copy()

# Mengatasi missing value pada harga_sebelumnya
X["harga_sebelumnya"] = X["harga_sebelumnya"].fillna(
    X["harga_sebelumnya"].median()
)

# Mengubah kolom stock menjadi angka
le_stock = LabelEncoder()
X["stock"] = le_stock.fit_transform(X["stock"])

# Mengubah kolom lead_time menjadi angka
le_lead = LabelEncoder()
X["lead_time"] = le_lead.fit_transform(X["lead_time"])

# Mengubah target kategori menjadi angka
le = LabelEncoder()
y = le.fit_transform(y)
```

```python
# Mengubah X menjadi array float64
X = np.array(X, dtype=np.float64)

# Mengubah y menjadi array int64
y = np.array(y, dtype=np.int64)

print("X:")
print(X)

print("y:")
print(y)
```

```
X:
[[1.86940e+02 4.36700e+02 0.00000e+00 1.00000e+00 4.80000e+00 2.05000e+02]
 [1.37450e+02 4.36700e+02 0.00000e+00 2.00000e+00 4.50000e+00 2.61000e+02]
 [8.86000e+01 4.36700e+02 1.00000e+00 4.00000e+00 3.20000e+00 1.25000e+02]
 ...
 [2.22113e+03 4.36700e+02 0.00000e+00 5.00000e+00 3.20000e+00 2.13000e+02]
 [1.28190e+02 4.36700e+02 0.00000e+00 4.00000e+00 4.60000e+00 1.10000e+02]
 [1.87350e+02 2.30810e+02 0.00000e+00 5.00000e+00 4.30000e+00 1.05000e+02]]
y:
[4 2 1 4 0 2 3 4 4 0 2 4 5 2 3 4 2 1 5 3 4 0 2 2 0 5 3 1 4 2 2 4 4 0 2 3 0
 0 0 3 1 2 0 4 1 4 4 1 2 0 2 4 0 4 2 4 4 4 2 2 1 5 5 2 4 0 1 0 2 2 4 5 1 4
 4 0 0 5 0 0 0 1 2 5 2 4 2 4 0 2 4 6 1 4 4 4 5 5 1 4 3 2 0 0 3 5 4 2 0 5 4
 4 2 4 4 4 2 2 4 4 4 2 1 4 0 2 3 4 4 0 2 4 5 2 3 4 2 1 5 3 4 0 2 2 0 5 3 1
 4 2 2 4 4 0 2 3 0 0 0 3 1 2 0 4 1 4 4 1 2 0 2 4 0 4 2 4 4 4 2 2 1 5 5 2 4
 0 1 0 2 2 4 5 1 4 4 0 0 5 0 0]
```

Kode ini digunakan untuk menyalin fitur X, mengisi data kosong pada harga_sebelumnya menggunakan nilai median, mengubah kolom stock, lead_time, dan target kategori menjadi angka menggunakan LabelEncoder, serta mengonversi X dan y menjadi array numerik, dengan output berupa matriks fitur 200 data produk dan array target kategori yang telah dienkode menjadi angka 0–5.

```python
# Hadijah Tohepaly-202431078
# 9. Membagi Data Latih dan Data Uji
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.3,
    random_state=0,
    stratify=y
)
```

```python
# Hadijah Tohepaly-202431078
# 10. Membuat Model Decision Tree

model = DecisionTreeClassifier()

# Melatih model
model.fit(X_train, y_train)

print("Model berhasil dilatih")
```

```
Model berhasil dilatih
```

Kode ini digunakan untuk membagi dataset menjadi 70% data latih dan 30% data uji dengan stratify=y agar proporsi kategori tetap seimbang, kemudian membuat model Decision Tree menggunakan DecisionTreeClassifier() dan melatihnya dengan model.fit(X_train, y_train), sehingga menghasilkan output “Model berhasil dilatih” yang menandakan model selesai mempelajari data latih.

```python
# Hadijah Tohepaly-202431078
# 11. Visualisasi Pohon Keputusan

plt.figure(figsize=(20, 10))

plot_tree(
    model,
    feature_names=[
        "harga",
        "harga_sebelumnya",
        "stock",
        "lead_time",
        "rating",
        "reviews"
    ],
    class_names=[str(kelas) for kelas in le.classes_],
    filled=True,
    rounded=True
)

plt.title("Visualisasi Decision Tree")
plt.show()
```



Kode ini digunakan untuk menampilkan visualisasi pohon keputusan dari model Decision Tree dalam ukuran 20×10 inci dengan nama fitur dan kategori kelas yang sesuai, sedangkan output berupa diagram pohon keputusan berwarna yang menunjukkan proses pemisahan data berdasarkan fitur hingga menghasilkan prediksi kategori produk.

```
# Hadijah Tohepaly-202431078
# 12. Prediksi Menggunakan 1 Data Baru

data_baru = pd.DataFrame([{
    "harga": 186.90,
    "harga_sebelumnya": 200.00,
    "stock": "In stock",
    "lead_time": "2 weeks",
    "rating": 4.8,
    "reviews": 209
}])

# Mengubah stock dan lead_time
data_baru["stock"] = le_stock.transform(data_baru["stock"])
data_baru["lead_time"] = le_lead.transform(data_baru["lead_time"])

# Mengubah menjadi array
data_baru = np.array(data_baru, dtype=np.float64)

# Prediksi
prediksi = model.predict(data_baru)

print("Hasil Prediksi:", le.inverse_transform(prediksi))
```

```
Hasil Prediksi: [0]
```

```
# Hadijah Tohepaly-202431078
# 13. Menghitung Akurasi

y_pred = model.predict(X_test)

akurasi = accuracy_score(y_test, y_pred)

print("Akurasi Model:", akurasi)
print("Akurasi (%):", akurasi * 100)
```

```
Akurasi Model: 0.13333333333333333
Akurasi (%): 13.333333333333334
```

Kode ini digunakan untuk mengubah satu data produk baru menjadi format numerik dan memprediksi kategorinya menggunakan model Decision Tree dengan output prediksi kelas 0 (kategori Decor), kemudian menghitung akurasi model berdasarkan data uji sebanyak 60 data dengan hasil 13,33%, yang menunjukkan bahwa model masih memiliki kemampuan prediksi yang rendah.

```
# Hadijah Tohepaly-202431078
# 14. Classification Report

print(classification_report(
    y_test,
    y_pred,
    target_names=[str(kelas) for kelas in le.classes_],
    zero_division=0
))
```

	precision	recall	f1-score	support
0	0.10	0.08	0.09	12
1	0.00	0.00	0.00	5
2	0.30	0.20	0.24	15
3	0.00	0.00	0.00	5
4	0.15	0.17	0.16	18
5	0.10	0.20	0.13	5
accuracy			0.13	60
macro avg	0.11	0.11	0.10	60
weighted avg	0.15	0.13	0.14	60

Kode classification_report() digunakan untuk mengevaluasi performa model berdasarkan nilai precision, recall, f1-score, dan support pada setiap kelas kategori, dengan output menunjukkan akurasi keseluruhan sebesar 13%, sehingga model Decision Tree masih kurang baik dalam mengklasifikasikan kategori produk pada data uji.

5. Naïve Bayes

```
# Hadijah Tohepaly - 202431078
# 1. Import Library

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import confusion_matrix, classification_report
```

Kode ini mengimpor library Pandas dan NumPy untuk mengolah data, Matplotlib dan Seaborn untuk visualisasi, LabelEncoder untuk mengubah data kategori menjadi angka, train_test_split untuk membagi data latih dan uji, GaussianNB untuk klasifikasi Naive Bayes, serta confusion_matrix dan classification_report untuk evaluasi model.

```
# Hadijah Tohepaly - 202431078
# 2. Membaca Dataset

df = pd.read_csv("heart.csv")

display(df.head())
```

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Kode pd.read_csv("heart.csv") digunakan untuk membaca dataset heart.csv dan menyimpannya ke dalam variabel df, sedangkan display(df.head()) menampilkan 5 baris pertama dataset. Output: Menampilkan 5 data pertama pasien yang berisi informasi usia, jenis kelamin, tekanan darah, kolesterol, dan kondisi penyakit jantung.

```
df.info()

display(df.describe())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    object
 2   ChestPainType   918 non-null    object
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
 6   RestingECG      918 non-null    object
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    object
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    object
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB
```

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
count	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368	0.887364	0.553377
std	9.432617	18.514154	109.384145	0.423046	25.460334	1.066570	0.497414
min	28.000000	0.000000	0.000000	0.000000	60.000000	-2.600000	0.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000	0.000000	0.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000	0.600000	1.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000	1.500000	1.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000	6.200000	1.000000

Kode df.info() digunakan untuk menampilkan informasi dataset seperti jumlah data, nama kolom, tipe data, dan nilai yang kosong, sedangkan df.describe() menampilkan statistik deskriptif berupa jumlah data, rata-rata, standar deviasi, nilai minimum, maksimum, serta kuartil. Output: Dataset memiliki 918 data dengan 12 kolom tanpa nilai kosong, terdiri dari 7 kolom numerik dan 5 kolom kategorikal, serta menampilkan ringkasan statistik dari setiap kolom numerik.

```
# Hadijah Tohepaly - 202431078
# 4. Memisahkan Fitur Numerik

fitur_kategorikal = [
    "Sex",
    "ChestPainType",
    "RestingECG",
    "ExerciseAngina",
    "ST_Slope"
]

fitur_numerik = [
    kolom for kolom in df.select_dtypes(include=np.number).columns
    if kolom != "HeartDisease"
]

print("Jumlah Fitur Numerik:", len(fitur_numerik))
print("Daftar Fitur Numerik:", fitur_numerik)
```

```
Jumlah Fitur Numerik: 6
Daftar Fitur Numerik: ['Age', 'RestingBP', 'Cholesterol', 'FastingBS', 'MaxHR', 'Oldpeak']
```

Kode ini digunakan untuk memisahkan fitur kategorikal dan numerik, dengan memilih kolom bertipe angka menggunakan select_dtypes() serta mengecualikan kolom target HeartDisease dari fitur numerik. Output: Diperoleh 6 fitur numerik, yaitu Age, RestingBP, Cholesterol, FastingBS, MaxHR, dan Oldpeak yang akan digunakan sebagai fitur dalam proses klasifikasi.

```
# Hadijah Tohepaly - 202431078
# 5. Memisahkan Fitur Kategorikal

print("Jumlah Fitur Kategorikal:", len(fitur_kategorikal))
print("Daftar Fitur Kategorikal:", fitur_kategorikal)
```

```
Jumlah Fitur Kategorikal: 5
Daftar Fitur Kategorikal: ['Sex', 'ChestPainType', 'RestingECG', 'ExerciseAngina', 'ST_Slope']
```

```
# Hadijah Tohepaly - 202431078
# 6. Menampilkan Nilai Unik Fitur Kategorikal

for kolom in fitur_kategorikal:
    print(kolom, ":", df[kolom].unique())
```

```
Sex : ['M' 'F']
ChestPainType : ['ATA' 'NAP' 'ASY' 'TA']
RestingECG : ['Normal' 'ST' 'LVH']
ExerciseAngina : ['N' 'Y']
ST_Slope : ['Up' 'Flat' 'Down']
```

Memisahkan Fitur Kategorikal Kode ini digunakan untuk menampilkan jumlah dan daftar fitur kategorikal yang telah ditentukan sebelumnya, yaitu 5 kolom bertipe kategori. Output: Terdapat 5 fitur kategorikal, yaitu Sex, ChestPainType, RestingECG, ExerciseAngina, dan ST_Slope. **Menampilkan Nilai Unik Fitur Kategorikal** Kode ini menggunakan perulangan for dan fungsi unique() untuk menampilkan seluruh nilai unik yang terdapat pada setiap fitur kategorikal. Output: Ditampilkan nilai kategori dari setiap kolom, seperti jenis kelamin M dan F, tipe nyeri dada ATA, NAP, ASY, TA, serta kategori lainnya pada RestingECG, ExerciseAngina, dan ST_Slope.

```
# Hadijah Tohepaly - 202431078
# 7. Mengubah Fitur Kategorikal Menjadi Angka

df_encoded = df.copy()

le = LabelEncoder()

for kolom in fitur_kategorikal:
    df_encoded[kolom] = le.fit_transform(
        df_encoded[kolom].astype(str)
    )

display(df_encoded.head())
```

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	1	1	140	289	0	1	172	0	0.0	2	0
1	49	0	2	160	180	0	1	156	0	1.0	1	1
2	37	1	1	130	283	0	2	98	0	0.0	2	0
3	48	0	0	138	214	0	1	108	1	1.5	1	1
4	54	1	2	150	195	0	1	122	0	0.0	2	0

Kode ini digunakan untuk menyalin dataset asli ke df_encoded, kemudian mengubah seluruh fitur kategorikal menjadi angka menggunakan LabelEncoder agar dapat diproses oleh algoritma Naive Bayes. Output: Ditampilkan 5 baris pertama dataset dengan fitur kategorikal yang sudah berubah menjadi nilai numerik, sedangkan kolom numerik dan target HeartDisease tetap seperti semula.

```
# Hadijah Tohepaly - 202431078
# 8. Memisahkan Fitur X dan Target Y

X = df_encoded.drop("HeartDisease", axis=1)
y = df_encoded["HeartDisease"]

print("Fitur X:")
display(X.head())

print("Target Y:")
display(y.head())
```

Fitur X:

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope
0	40	1	1	140	289	0	1	172	0	0.0	2
1	49	0	2	160	180	0	1	156	0	1.0	1
2	37	1	1	130	283	0	2	98	0	0.0	2
3	48	0	0	138	214	0	1	108	1	1.5	1
4	54	1	2	150	195	0	1	122	0	0.0	2

Target Y:

```
0    0
1    1
2    0
3    1
4    0
Name: HeartDisease, dtype: int64
```

Kode ini digunakan untuk memisahkan dataset menjadi fitur X yang berisi seluruh kolom input kecuali HeartDisease, serta target y yang berisi nilai HeartDisease sebagai label klasifikasi. Output: Ditampilkan 5 baris pertama fitur X dan target Y, dengan target bernilai 0 (tidak mengalami penyakit jantung) atau 1 (mengalami penyakit jantung).

```
# Hadijah Tohepaly - 202431078
# 9. Membagi Data Training dan Testing

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.25,
    random_state=0
)

print("Jumlah Data Training:", len(X_train))
print("Jumlah Data Testing:", len(X_test))
```

```
Jumlah Data Training: 688
Jumlah Data Testing: 230
```

```
# Hadijah Tohepaly - 202431078
# 10. Membuat dan Melatih Model Gaussian Naive Bayes

model = GaussianNB()

model.fit(X_train, y_train)

print("Model Gaussian Naive Bayes Berhasil Dilatih")
```

```
Model Gaussian Naive Bayes Berhasil Dilatih
```

Membagi Data Training dan Testing Kode train_test_split() digunakan untuk membagi dataset menjadi data training sebesar 75% dan data testing sebesar 25%, dengan random_state=0 agar pembagian data tetap konsisten. Output: Diperoleh 688 data training dan 230 data testing dari total 918 data. **Membuat dan Melatih Model Gaussian Naive Bayes** Kode GaussianNB() digunakan untuk membuat model klasifikasi Naive Bayes, kemudian model.fit(X_train, y_train) melatih model menggunakan data training agar dapat mengenali pola penyakit jantung. Output: Muncul pesan Model Gaussian Naive Bayes Berhasil Dilatih yang menandakan model selesai dilatih menggunakan data training.

```
# Hadijah Tohepaly - 202431078
# 11. Melakukan Prediksi Data Training dan Testing

y_pred_train = model.predict(X_train)
y_pred_test = model.predict(X_test)

print("Prediksi Data Training:")
print(y_pred_train)

print("\nPrediksi Data Testing:")
print(y_pred_test)
```

```
Prediksi Data Training:
[0 1 1 0 1 1 1 0 1 1 0 0 1 0 1 1 0 0 0 1 0 1 1 0 0 0 1 0 1 1 0 0 0 1 0 1 1
 0 1 0 0 1 1 0 1 1 0 1 0 1 1 0 0 1 0 1 1 0 1 1 0 1 0 1 1 0 1 1 0 1 0 1 1 0
 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1
 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1
 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1 1 0 1
```